# 通道重排 × 混合 MXFP 激活 × HMT

AutoRound 的算法与工程设计：以 Intel GPU / XPU 为主

## 让 4 位量化更准
## 也让实现路径可验证

F1 固定 K 轴重排 + MXFP4

F2 主体 A4 + 少量 A8

HMT 可选、成对补偿、联合优化

13 个固定来源 · 作者图表 · 真实代码落点 · 分阶段开发方案

# 建议：一份计划，两个功能，三层落地

先验证数值与精度，再选择真实硬件路径。默认不升级权重位宽。

## F1 / 改变分组

离线学习固定置换

激活与权重列同步重排

重新形成 32 元素块

先用完整 W4A4

## F2 / 分配精度

一次 gather 得到两区

主体激活 MXFP4

少量激活 MXFP8

默认两区权重均 MXFP4

## HMT / 可选增强

分区后先旋转低区

固定 H32 作为起点

两侧严格配对补偿

学习旋转放后续

**参考 QDQ → XPU 解码融合 → 经能力探测的原生运算**

# 先讲证据边界：哪些知道，哪些尚未证明

作者结果、理论推导、开发目标不能混为一谈。

| 证据级别 | 本次已核验 | 不能据此声称 |
| --- | --- | --- |
| 代码事实 | AutoRound 固定提交；作者算法 / 内核实现 | 相关路径已完成生产验证 |
| 作者报告 | 原始论文图、作者 CSV 、固定 README 结果 | 新功能已在 XPU 达到同等收益 |
| 推导与设计 | 配对变换公式、预算和对齐计算 | 实际延迟与理论字节成本相同 |
| 待验证 | 候选算法、门槛、开发估算 | 已取得精度提升或加速 |

访问限制：论文站点直连失败；以作者公开实现、作者论文图与原始数据核验。

完整提交与哈希见 evidence.json ；不声称通读全部全文或穷尽所有工作。

# 最接近的先行工作，决定创新应放在哪里

不是提出新格式；重点是 AutoRound 优化、 XPU 和 MoE 的联合落地。

| 方向 | 最相关工作 | 本方案的增量 |
| --- | --- | --- |
| 通道重排 | RPTQ ； DuQuant | 重构损失驱动、局部性约束 |
| MXFP4 + 旋转 | DuQuant++ ； FP-Quant | 与 AutoRound rounding 联合选型 |
| 少量高精度特征 | LLM.int8 / QUIK / Atom | 默认 W4 ，激活 A4/A8 |
| 混合 MX 通道 | MicroMix （ ICLR 2026 分支） | XPU 双分区 ABI 、 MoE 共享 / 分桶 |
| 数据感知变换 | SpinQuant ； WUSH | 成本匹配的进阶探索，不纳入首期 |

# QuaRot：成对旋转，而不是单边处理异常值

作者原图 / INT4 工作；用于说明旋转思想，不是 MXFP4 或 XPU 新结果。




**核心迁移原则：函数保持不变，量化误差才是优化对象。**

来源 R05 · spcl/QuaRot@5008669 · Apache-2.0

# DuQuant： 旋转 → 置换 → 再旋转

作者原图：先处理块内异常值，再平衡块间分布。不能据此认定随机 shuffle 一定有效。

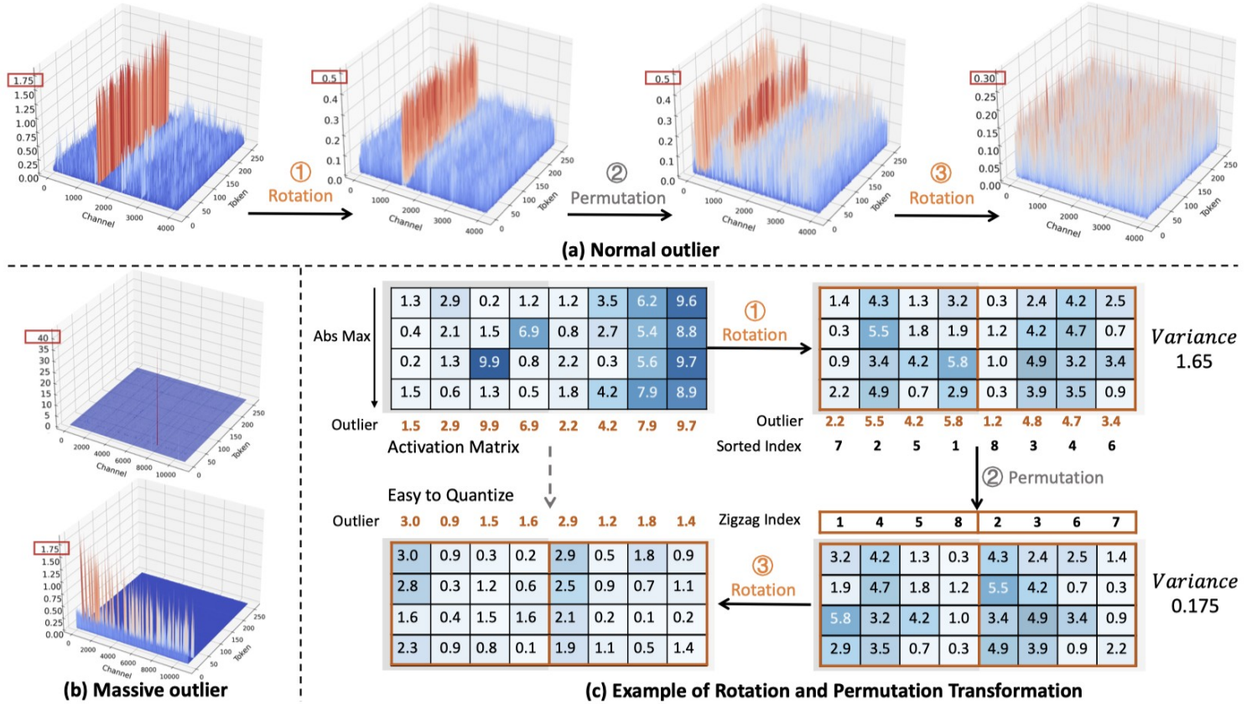



**Figure:** Transformation Steps for Activation Matrices after smooth technique. (a) Sequential transformations on Normal Outliers: ① initial rotation to reduce outliers within blocks, ② permutation to evenly distribute outliers across blocks, and ③ a second rotation for further smoothing. (b) Activation changes for Massive Outliers before and after DuQuant. (c) A sample matrix for highlighting the continual reduction of outliers through rotation and permutation, with outliers marked in dark blue.

来源 R03 · MIT； R04 为独立的后续 MXFP4 实现。

## 两种分组目标

无 HMT： 相近幅度聚集

有 HMT： 测试异常值均摊

二者都用完整 QDQ 验证

## 更直接的 MXFP4 对照

DuQuant++ （2026）

块长 32 、细粒度旋转

额外尺度约定需重新对齐

# DuQuant 的原始数据表：保留格式和上下文

W4A4 整数实验； 1-* / 2-* 为 LLaMA-1 / LLaMA-2 。 PPL 越低越好。

| Dataset | #Bit | Method | 1-7B | 1-13B | 1-30B | 1-65B | 2-7B | 2-13B | 2-70B |
|---|---|---|---|---|---|---|---|---|---|
| WikiText2 | FP16 | - | 5.68 | 5.09 | 4.10 | 3.53 | 5.47 | 4.88 | 3.31 |
| | W4A4 | SmoothQuant | 25.25 | 40.05 | 192.40 | 275.53 | 83.12 | 35.88 | 26.01 |
| | | OmniQuant | 11.26 | 10.87 | 10.33 | 9.17 | 14.26 | 12.30 | NaN |
| | | AffineQuant | 10.28 | 10.32 | 9.35 | - | 12.69 | 11.45 | - |
| | | QLLM | 9.65 | 8.41 | 8.37 | 6.87 | 11.75 | 9.09 | 7.00 |
| | | Atom | 8.15 | 7.43 | 6.52 | 5.14 | 8.40 | 6.96 | NaN |
| | | **DuQuant** | 6.40 | 5.65 | 4.72 | 4.13 | 6.28 | 5.42 | 3.79 |
| | | **DuQuant+LWC** | **6.18** | **5.47** | **4.55** | **3.93** | **6.08** | **5.33** | **3.76** |
| C4 | FP16 | | 7.08 | 6.61 | 5.98 | 5.62 | 6.97 | 6.46 | 5.52 |
| | W4A4 | SmoothQuant | 32.32 | 47.18 | 122.38 | 244.35 | 77.27 | 43.19 | 34.61 |
| | | OmniQuant | 14.51 | 13.78 | 12.49 | 11.28 | 18.02 | 14.55 | NaN |
| | | AffineQuant | 13.64 | 13.44 | 11.58 | - | 15.76 | 13.97 | - |
| | | QLLM | 12.29 | 10.58 | 11.51 | 8.98 | 13.26 | 11.13 | 8.89 |
| | | Atom | 10.34 | 9.57 | 8.56 | 8.17 | 10.96 | 9.12 | NaN |
| | | **DuQuant** | 7.84 | 7.16 | 6.45 | 6.03 | 7.90 | 7.05 | 5.87 |
| | | **DuQuant+LWC** | **7.73** | **7.07** | **6.37** | **5.93** | **7.79** | **7.02** | **5.85** |

来源 R03 · Hsu1023/DuQuant@d56cfc6 · MIT

## 怎样读这张表

比较同一模型和数据集

保留 NaN 与缺失值

不把 INT4 写成 MXFP4

不外推 Intel 加速比

# MicroMix： 与 F2 最接近的直接先行实现

原创概念重绘，不复制该仓库图片 / 源码；固定核验 micromix 分支。

### 通道统计

静态收集激活

生成固定排序

### 比例与重排

按精度分成连续区

原实现含 4 / 6 / 8

### 混合 GEMM

W4A4 / W4A8 等

Blackwell 内核

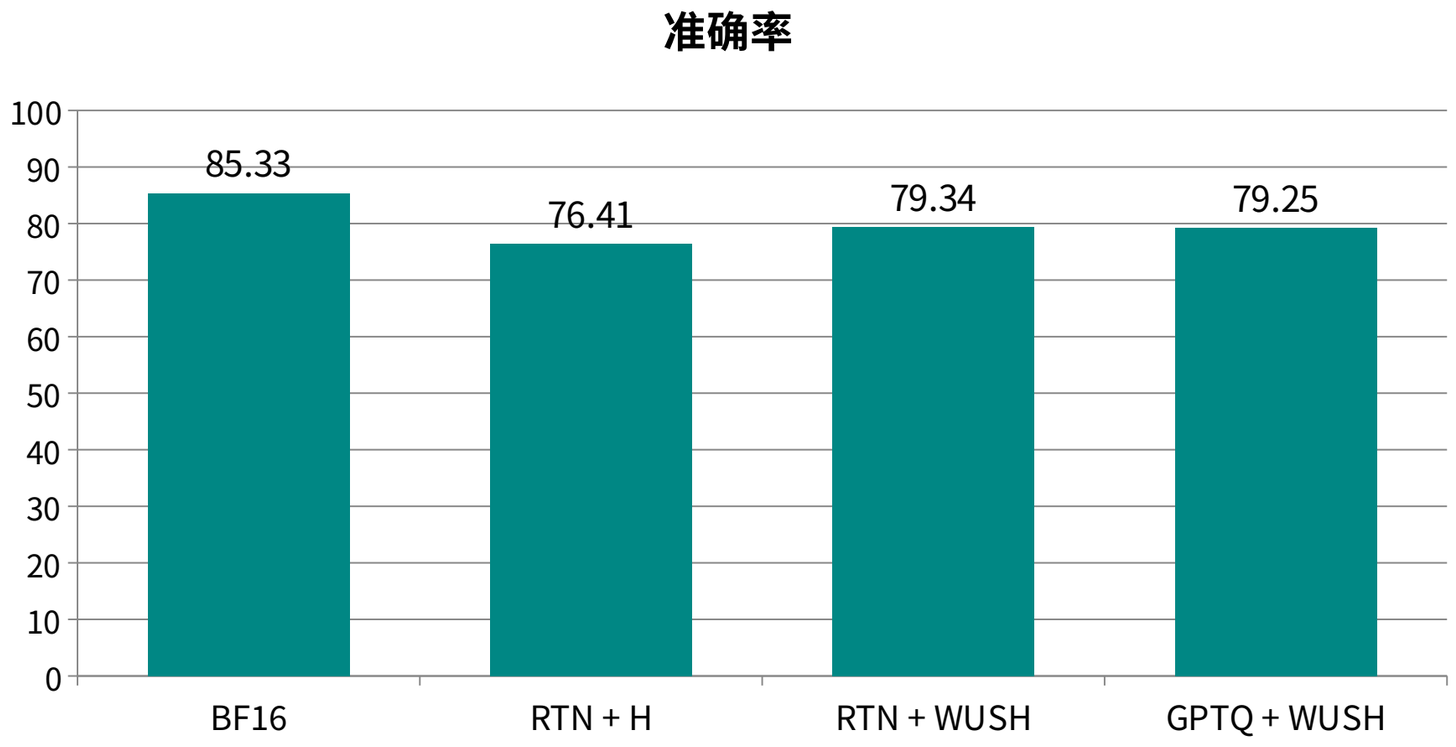
**核验到真实 MXFP8 激活 × MXFP4 权重；不应把高分支默认改成 W8A8 。**

原实现按 128 通道对齐比例； XPU 对齐需重新确定。

MVP 只做 4/8 两区，避免同时引入 FP6 的数值与部署复杂度。

# 直接的 MXFP4 证据：固定 HMT 仍有改进空间

WUSH 作者数据 · Llama-3.1-8B-Instruct · 13 个 Platinum 任务宏平均准确率（%）




| 作者方法 | 准确率 | 记录 |
|---|---|---|
| BF16 | 85.33 | 1 |
| RTN-H | 76.41 | 5 |
| RTN-WUSH | 79.34 | 5 |
| GPTQ-WUSH | 79.25 | 5 |

**+2.93 个百分点**

RTN-WUSH 相对 RTN-H

仍落后 BF16 5.99 点

记录数不等于独立种子

来源 R12 · 原始 CSV 随包提供 · 图表为可编辑 PowerPoint chart

# 格式不混淆： MXFP4 、 MXFP8 、 NVFP4

每个数字比较都要先对齐数值 profile 。

| 格式 | 元素 | 共享尺度 | 本方案 |
| --- | --- | --- | --- |
| MXFP4 | E2M1 ； 最大幅值 6 | E8M0 ， 32 元素 | 低区与默认全部权重 |
| MXFP8 | 默认 E4M3 ； E5M2 可选 | E8M0 ， 32 元素 | 高激活分区 |
| NVFP4 | E2M1 | 不同块长与尺度约定 | 独立对照，不混报结果 |

## MXFP4 幅值： 0 · 0.5 · 1 · 1.5 · 2 · 3 · 4 · 6

ARK / core floor / rceil / CUDA HMT 并非完全同约定。

冻结舍入、零块、符号零、尺度、 nibble 顺序；禁止校准与导出悄悄切换 profile 。

# 不变量：激活和权重列必须成对变换

约定 X[M,K] 、 W[N,K] ， Y = X W^T + b 。

$$X' = X[:, p] \quad W' = W[:, p] \quad X' (W')^T = X W^T$$

## 正交 HMT

R R^T = I

X' = X P R

W' = W P R

## 一般可逆 T

X' = X T

$W' = W T^{-T}$

WUSH 不能套用两侧同乘 T

**这是 K 轴重排，不是 token 路由；最终 N 维输出不需要逆置换。**

# F1： 要优化跨块成员，而非“打乱”本身

没有跨量化块变化时， shuffle 应作为负对照，而不是收益来源。

| | | | | | | |
|---|---|---|---|---|---|---|
| **原顺序（示意）** | 0.4 | 7.8 | 0.3 | 6.2 | 0.5 | 9.1 |
| **候选重排** | 0.3 | 0.4 | 0.5 | 6.2 | 7.8 | 9.1 |

## 无 HMT： 测试幅度相近的分组

按 RMS / 分位数 / log 幅度排序

权重列范数与量化残差共同打分

## 有 HMT： 还要测试异常值均摊

zigzag / 块交换 / 局部性约束

同样用完整 W4A4 输出损失验证

数值与小方块仅为原创示意；实际共享尺度块为 32 元素。

# F1 搜索：用重构损失，而不只用 amax

先廉价筛选，再短程 AutoRound ；排列在调优期间固定。

| 候选 | 复杂度 / 目标 | 筛选原则 |
| --- | --- | --- |
| identity / random | 必须有的基线 | 固定种子；跨块与块内对照 |
| RMS / 分位数排序 | O(K log K) | 幅度相近；加入权重敏感度 |
| zigzag + HMT | 异常值跨旋转块均摊 | 与聚类路线直接对比 |
| 局部交换 | 限制 128/256/512 窗口 | 精度收益 + 实际 gather 成本 |

**损失 = || 原层输出 − 完整 QDQ 层输出 ||² / (|| 原层输出 ||² + ε)**

QKV / gate-up 等共享输入的消费者联合归一化打分，避免重复 gather 。

# grouped GEMM： M 轴 routing 与 K 轴 gather 分开

两种重排不要混为一种；保留 top-k 权重和最终 scatter 对应关系。

### token × top-k

原 token id

router 权重

### 按 expert 排序

M 轴 gather

生成专家区间

### 通道计划

K 轴 gather

共享 / 专家计划

### grouped GEMM

双分区累加

scatter/reduce

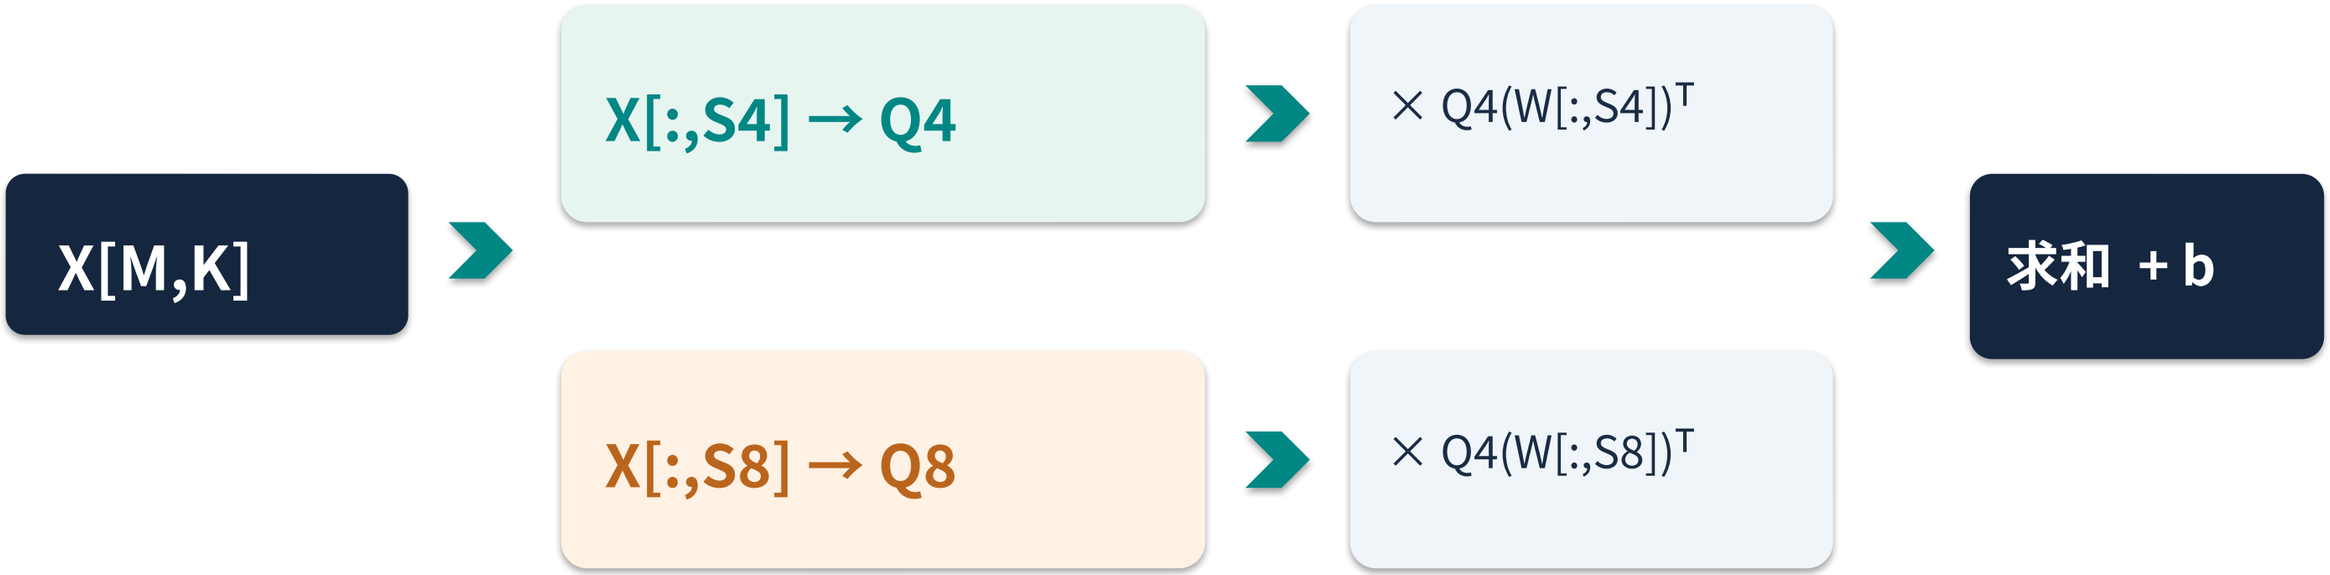
MVP： 专家组共享计划； gate/up 共用预处理。

下一步：每专家 mask + 固定 K8 档位，按形状 /profile/HMT 分桶。

down-proj 是每专家自己的中间激活，不能无条件复用 gate/up 计划。

# F2： 一遍 gather，两段连续输入，沿 K 求和

默认是低区 W4A4 + 高区 W4A8；不是两个完整 K 的 GEMM。




**S4 ∩ S8 = ∅ ， S4 ∪ S8 = 全部 K； bias 只加一次。**

# 高分支有三种语义，必须分开报告

权重存储格式、实际操作数格式、量化精度不是同一个概念。

| 方案 | 高区权重 | 解释 |
| --- | --- | --- |
| 默认 W4A8 | 原始权重 → MXFP4 | 只提高激活精度；严格对应需求 |
| W4 码展开为 W8 操作数 | E2M1 → E4M3 无损码转换 | 权重数值不变；运行时缓存可能增大 |
| 可选 W8A8 | 原始权重 → MXFP8 | 权重量化也升级；额外预算、单独消融 |

**E2M1 的有限值可被 E4M3 精确表示，但尺度布局与设备数值仍需验证。**

若不支持 A8W4： 显式选择无损展开或解码路径。

不允许把 INT4/INT8 内核改名后当作 MXFP4/MXFP8 。

# 给谁 A8：量化误差增益优先，幅度只是代理

移动通道会改变整个共享尺度块，通道收益并不天然可加。

### 廉价候选分数

RMS × 权重列范数

高分位 / 尾部频次

A4→A8 的误差改善

### 必须真实复算

重新 gather 与分组

两区全部尺度重算

计算完整层输出误差

### 再做预算选择

边界通道交换

固定实际 K8 比较

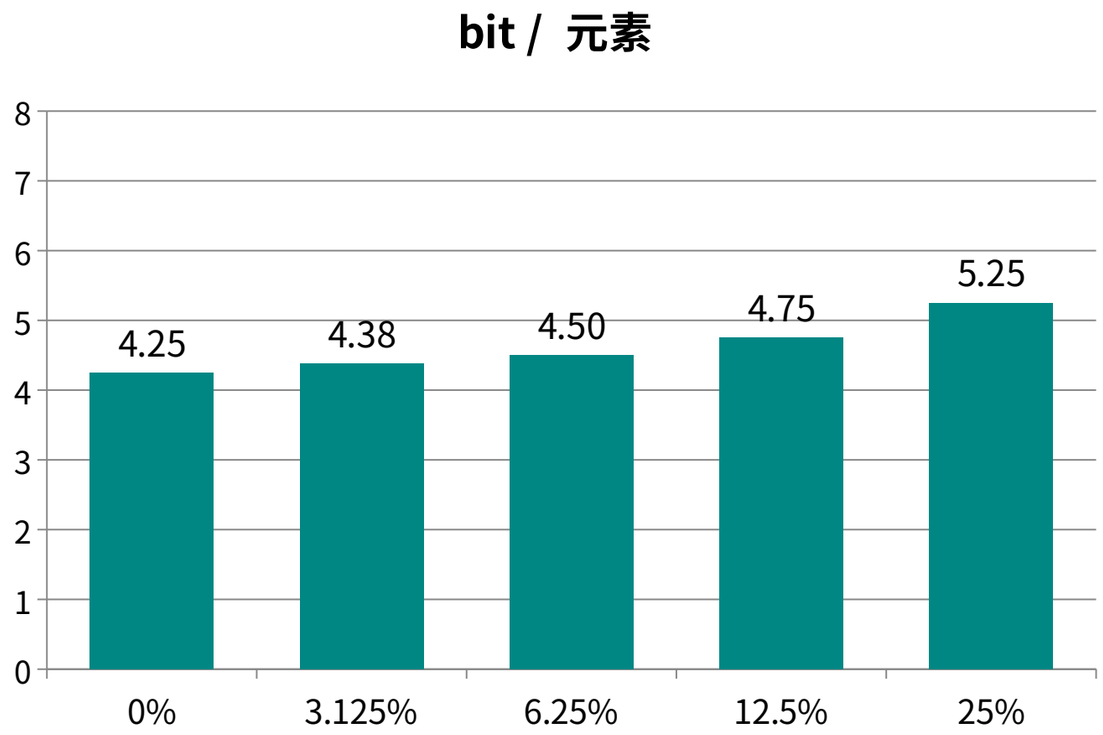
全模型收益 / 成本分配

$$s[j] \approx ||Q4(W)[:,j]||^2 \times E[err4(xj)^2 - err8(xj)^2]$$

仅是固定尺度 / 分组下的筛选代理；最终选择由完整分区 QDQ 决定。

# 小比例不是连续旋钮：对齐决定真实预算

理论 activation payload ，未计 padding 、索引、布局、展开缓存；不是性能实测。




| K | 目标 | K8 | 实际 |
|---|---|---|---|
| 768 | 1% | 32 | 4.17% |
| 2048 | 1% | 32 | 1.56% |
| 4096 | 1% | 64 | 1.56% |
| 4096 | 5% | 224 | 5.47% |

## 4.25 + 4ρ bit / activation 元素

6.25% A8 → 4.50 bit， payload +5.88% 。

默认不增加 checkpoint 权重位宽。

# HMT 组合：先明确 mask 属于哪个坐标基

推荐从 H1 开始； PR 与 RP 一般不相等。

| 方案 | 顺序 | 风险 / 作用 |
| --- | --- | --- |
| H0 | 分区 → A4/A8 ，无 HMT | 分离两个功能自身收益 |
| H1 / 推荐 | 原坐标选高区 → 分区 → 仅低区 HMT | 高敏感通道不被混回低区 |
| H2 | 全输入 HMT → 重新校准选通道 | 旧坐标 mask 无效 |
| H3 | 分区 → 两区独立 HMT | 高区小 K 的 padding/ 开销 |
| H4 | 旋转 → zigzag → 再旋转 | DuQuant 风格；两次变换不免费 |

**先比较 H32 / 随机符号 H32 ，再扩至 128/256/512 ； MX 量化 group 始终 32 。**

# 统一搜索：离散计划与 AutoRound 交替优化

恢复 / 重建调优状态，避免旧排列的梯度、尺度与统计被误用。

## 01

### 统计与候选

路由加权统计

identity / 聚类 / zigzag

## 02

### 分区与 HMT

在正确坐标选 S8

重算尺度与完整 QDQ

## 03

### 短程调优

前 2–4 名跑 AutoRound

独立选型集重排

## 04

### 成本选择

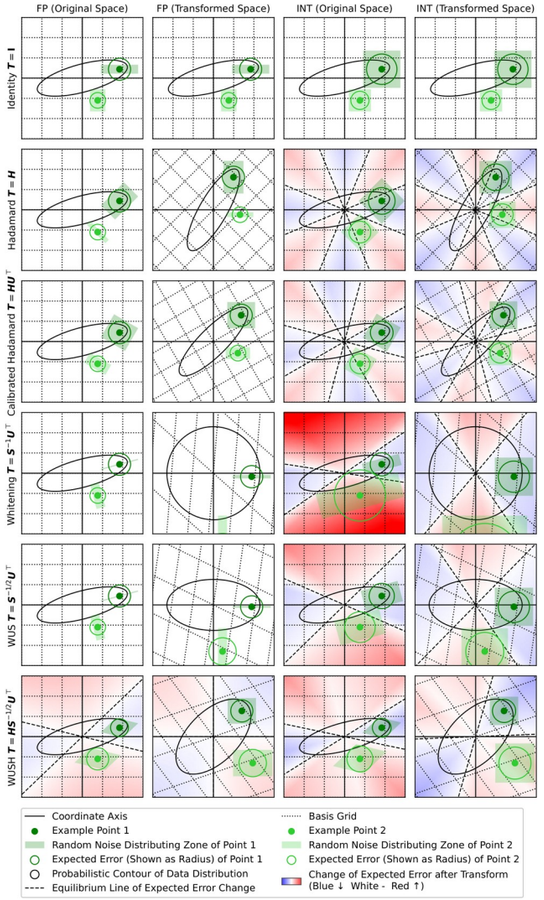
实测 XPU 成本 Pareto

冻结计划、最终调优

**J = 重构损失 + λ × 完整实测延迟 + μ × 驻留字节**

# 进阶方向：从固定 HMT 到数据感知变换

WUSH 作者原图：不是所有最优候选都是正交旋转。




来源 R12 • Apache-2.0 • 左图可放大阅读，解释为本报告原创。

## 为什么值得比较

同时利用权重与激活二阶统计

固定 Hadamard 不一定最优

但理论假设不等于任务保证

## 为什么不作为首期默认

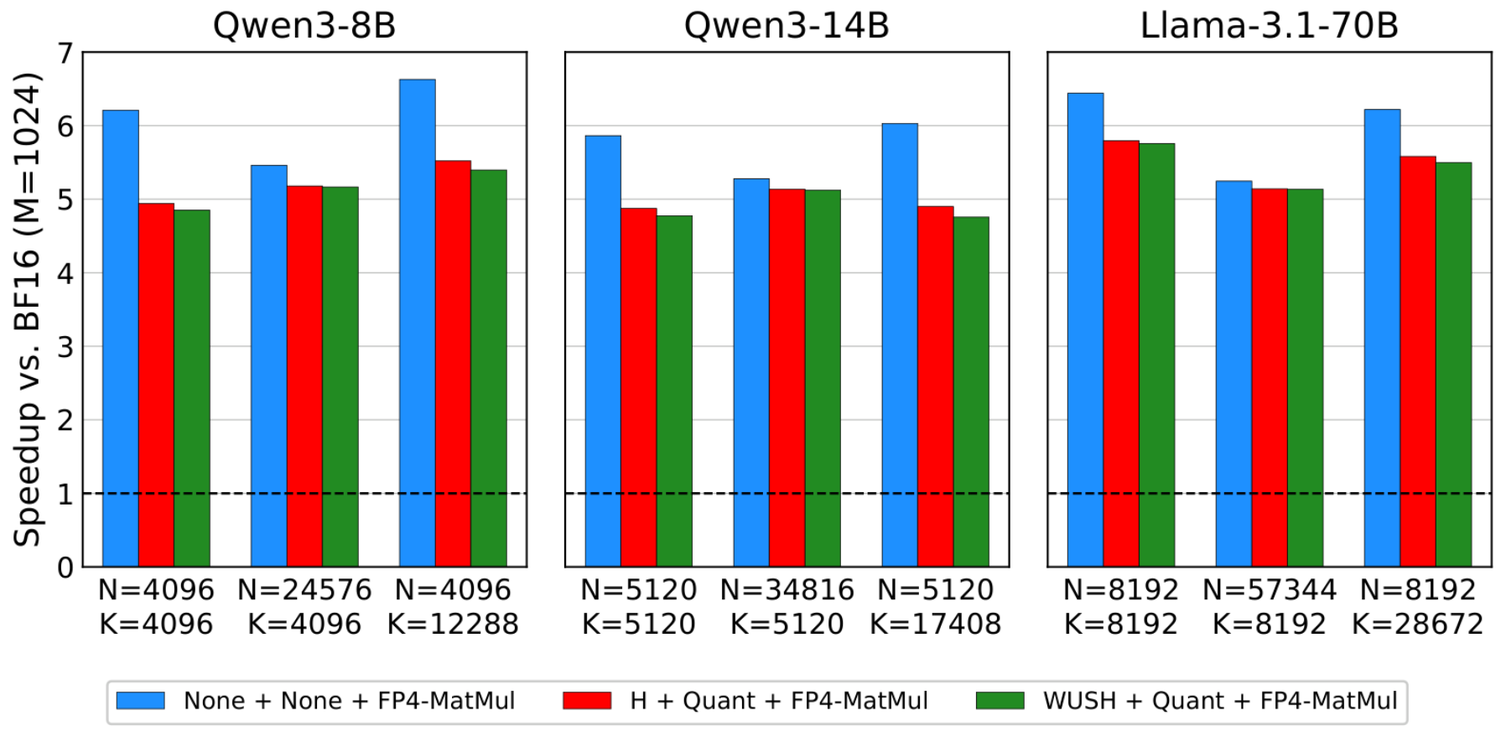
非正交变换需 $W T^{-T}$ 补偿

稠密小矩阵与尺度成本要实测

与可学习旋转按真实成本对齐

# 论文速度图能说明什么，不能说明什么

WUSH 作者图 2： M=1024，逐层相对 BF16；不是端到端或 Intel 数据。




**变换与量化开销必须计入，但仍可能保留部分内核收益。**

图 / 绘图脚本未明确 GPU 型号，不据此做跨硬件比较。来源 R12 · Apache-2.0 。

# AutoRound 落点：复用已有机制，不另起一套

基线 5db1082；新的计划是前处理 / 量化包装层，不是新 scalar dtype。

| 层 | 现有机制 | 拟开发增量 |
| --- | --- | --- |
| 方案与数值 | schemes.py； data_type/mxfp.py | 显式计划 schema；复用 4/8 QDQ |
| 组合与校准 | composer； BasePreprocessor | 计划冻结、参考失效、坐标统计 |
| 调优与 grouped | wrapper； grouped_experts.py | 分区 QDQ 、梯度、计划签名 / 分桶 |
| XPU 内核 | ARK HMT + MXFP4 原语 | gather / sign / 双区输出 + GEMM 消费 |
| 保存与推理 | qlinear_fp； formats； backend | 两区 packed buffers 、版本化重载 |

**开关默认关闭；旧模型、旧 preset 、旧导出结果保持不变。**

# 三个真实缺口： hook 、 packed 消费者、后端能力

代码存在，不等于已经自动进入模型推理路径。

## grouped 的 hook 限制

现有在线变换 hook 会退出部分 grouped 快速路径。

需显式计划阶段，而非只挂 hook 。

## 已有 HMT 原语

XPU 原语产出 packed FP4

但不证明已接入 dense / MoE MXFP4 activation GEMM 。

## 现有 W4A8 并非 MX

ARK 路径是 INT4 存储加 INT8 DPAS 计算；

部分 FP8 代码待硬件验证。

**把实际分派路径、 fallback 原因、 workspace 与代码版本纳入 benchmark 记录。**

# Intel XPU： 按代际核验原生计算，而不是按名称猜测

oneDNN 固定主分支提交 4149450； 不是用户已安装版本的保证。

| 架构 | FP8 | FP4 E2M1 |
| --- | --- | --- |
| Xe-HPC | 转换 | 转换 |
| Xe2-HPG | 转换 | 转换 |
| Xe3-LPG | 转换 | 转换 |
| Xe3p-LPG | 原生 | 转换 |
| Xe3p-XPC | 原生 | 原生 |

**还必须实际创建 primitive： A8W4？ 块尺度布局？ grouped / ragged？**

记录 GPU id / 驱动 / oneAPI / oneDNN / ARK 版本； unimplemented 显式失败。

# 内核路线：参考、解码融合、能力通过后的原生

同一 packed ABI 与同一数值契约，三种执行层次。

| 层次 | 实现 | 收益 / 限制 |
| --- | --- | --- |
| Reference | FP32 变换 + QDQ ；拼接后高精度 GEMM | 定义正确性；不能用其推理时间代表低位内核 |
| 转换计算设备 | load 解码 FP4/FP8 ；组尺度； FP16/BF16 DPAS | 减少存储和完整解码 workspace ；不宣称原生 FP4 算力 |
| 原生设备 | 支持的 block-scaled 算子；双分支或融合累加 | 每个 operand/shape/profile 都需能力验证 |

**融合目标： routing + gather + sign + HMT + quantize + pack**

# 持久化：一份版本化计划贯穿校准、调优、推理

拟议 schema ，不是当前可调用 API ；不把未知字段塞入会过滤字段的 from_dict 。

| 元数据 | 张量 buffers | 加载校验 |
| --- | --- | --- |
| version / profile / transform_order | 实际 permutation 、 sign | 维度、排列完整性、哈希 |
| mask_basis / logical K / padded K4,K8 | 两区 packed 权重 + E8M0 尺度 | 分区不重叠、覆盖 K 、组边界 |
| 共享计划关系 / 已变换权重标记 | 可选无损展开缓存不当作原权重 | 应用一次；不重复旋转 |

**save → shard/offload → load → generate 都必须保留同一计划。**

safetensors buffers ；旧 checkpoint 兼容； TP 首期仅 rank-local K 置换。

不支持的 backend 明确报错，只有显式允许时才做带日志的 reference 回退。

# 正确性：先查不变量，再查编码，最后查网络

不同累加顺序不强求字节相同；匹配 profile 的 packed 编码应严格一致。

| 层级 | 关键测试 |
| --- | --- |
| 数学 | 配对置换、正交 / 逆转置、只变一侧负测试、归一化因子 |
| 编码 | tie 、全零 / 负零、极值 / 次正规、 NaN/Inf 、 E8M0 保留值 |
| 分区 | 空 / 全 S8 、尾块、重复 / 越界索引拒绝、 bias 一次、 padding 保留 |
| grouped | 空专家、热点、 top-k scatter 、共享 / 独立计划、签名 /fallback |
| 生命周期 | 梯度 /STE 、 quantize-save-load 、即时 shard 、 meta/offload 、旧模型 |

**禁用开关时行为不变；不把随机模型的小规模通过当作真实模型精度结论。**

# 实验：公平预算，独立数据，真实 MoE 负载

tiny → dense → MoE；覆盖 prefill 与 decode，而不只测大 M GEMM。

| 维度 | 推荐矩阵 |
| --- | --- |
| 基线 | BF16；原 MXFP4 RTN / AutoRound； F1、F2、组合，各自 ±HMT |
| 预算 | 相同实际 K8、全部 W4、同校准量 / 调优轮数； W8 高区单列 |
| 形状 | M=1/8/32/128/1024； K=768/2048/4096/11008 等真实投影 |
| MoE | E=8/64/128， top-k=2/8；均衡、长尾、空专家、热点 |
| 泛化 | 校准 / 选型 / 最终评测分离；代码数学、长上下文、分布外；≥ 3 种子 |

**记录路由覆盖；强制覆盖样本不能悄悄替代真实 token 权重。**

# 建议门槛：是研发目标，不是已经取得的结果

明确区分质量研究成功与硬件算术加速成立。

## 质量门槛 / 建议

2 dense + 1 MoE

选型集中位层误差下降 ⩾ 20%

最终任务 /PPL 无实质回退

至少一项实际改善

## 工程门槛 / 建议

先测试 K8⩽6.25% 档

完整投影延迟 ⩽ 1.10× 基线

记录峰值 / 驻留显存

整模型 Pareto 决策

**总延迟 = routing + gather + HMT + 量化 + 两分支 GEMM + 求和 + scatter**

同机、同预算、预热后中位数 /p95； kernel / block / TTFT / TPOT 分开报告。

# 探索优先级：先解决四个可证伪的问题

后续的学习旋转、动态 mask 和 MXFP6 ，都应受真实成本约束。

| 优先级 | 方向 | 可证伪问题 |
| --- | --- | --- |
| P0 | 误差增益选 A8 | 相同 K8 下，是否胜过只按最大幅度? |
| P0 | HMT + A8 | 互补还是替代? 能否降低必要 A8 预算? |
| P0 | 局部性约束置换 | 能否保留精度，同时减少随机 gather 损失? |
| P0 | MoE 共享 / 专家计划 | 独立计划收益是否覆盖 top-k 重复处理? |
| P1 | 指数边界、全模型预算、 WUSH/SpinQuant | 同成本下是否更好? 正确补偿是否可部署? |
| P2 | 动态 mask 、 W8/ 低秩旁路、 MXFP6 | 额外精度与额外成本能否单独归因? |

# 开发里程碑：数值、 dense 、 grouped 、持久化闭环

人日是工程估算，不是排期承诺；算法 / 内核工程师可部分并行。

| 阶段 | 交付物 | 依赖 | 估算 |
| --- | --- | --- | --- |
| M0 | 设备能力 / profile / packed ABI / baseline | 实际 XPU | 2–3 人日 |
| M1 | CPU reference / F1-F2 dense / 负对照 | M0 | 4–6 |
| M2 | HMT / 搜索 / AutoRound wrapper | M1 | 5–8 |
| M3 | XPU 前处理融合 / dense 双分支 | M0/M1； HMT 需 M2 | 6–10 |
| M4 | 专家共享计划 / 分桶 / decode | M2/M3 | 6–10 |
| M5 | 导出重载 / shard-TP / 完整评测 | M2/M3； MoE 需 M4 | 5–8 |

# 最终决策：用 Pareto 证据，而不是单项宣传

不把“更准”“更小”“更快”当作同一个结论。

## 先做 M0 / M1，再决定值得投入哪条内核路线。

保留：同预算下真实精度改善的静态计划。

推进：完整成本受控、能导出重载的 XPU 路径。

停用：校准集好看但泛化变差、或 gather 成本失控的候选。

**核心贡献： AutoRound × 通道预算 × HMT × Intel XPU / MoE**

# 参考来源 1/2： 论文入口与固定实现版本

完整作者标题、 URL 、文件 SHA256 、许可和证据说明见 evidence.json 及逐页备注。

| ID | 工作 / 资料 | 论文编号 | 核验提交 |
|---|---|---|---|
| R01 | Microscaling / OCP MX | 2310.10537 | 7bc4195 |
| R02 | RPTQ | 2304.01089 | 9619069 |
| R03 | DuQuant | 2406.01721 | d56cfc6 |
| R04 | DuQuant++ | 2604.17789 | 6c13ec0 |
| R05 | QuaRot | 2404.00456 | 5008669 |
| R06 | SpinQuant | 2405.16406 | 8f47aa3 |
| R07 | LLM.int8() / bitsandbytes | 2208.07339 | a616886 |

图像仅复用明确 MIT / Apache 作者资产； MicroMix / Atom / SpinQuant 不复制插图。

# 参考来源 2/2： 论文入口与固定实现版本

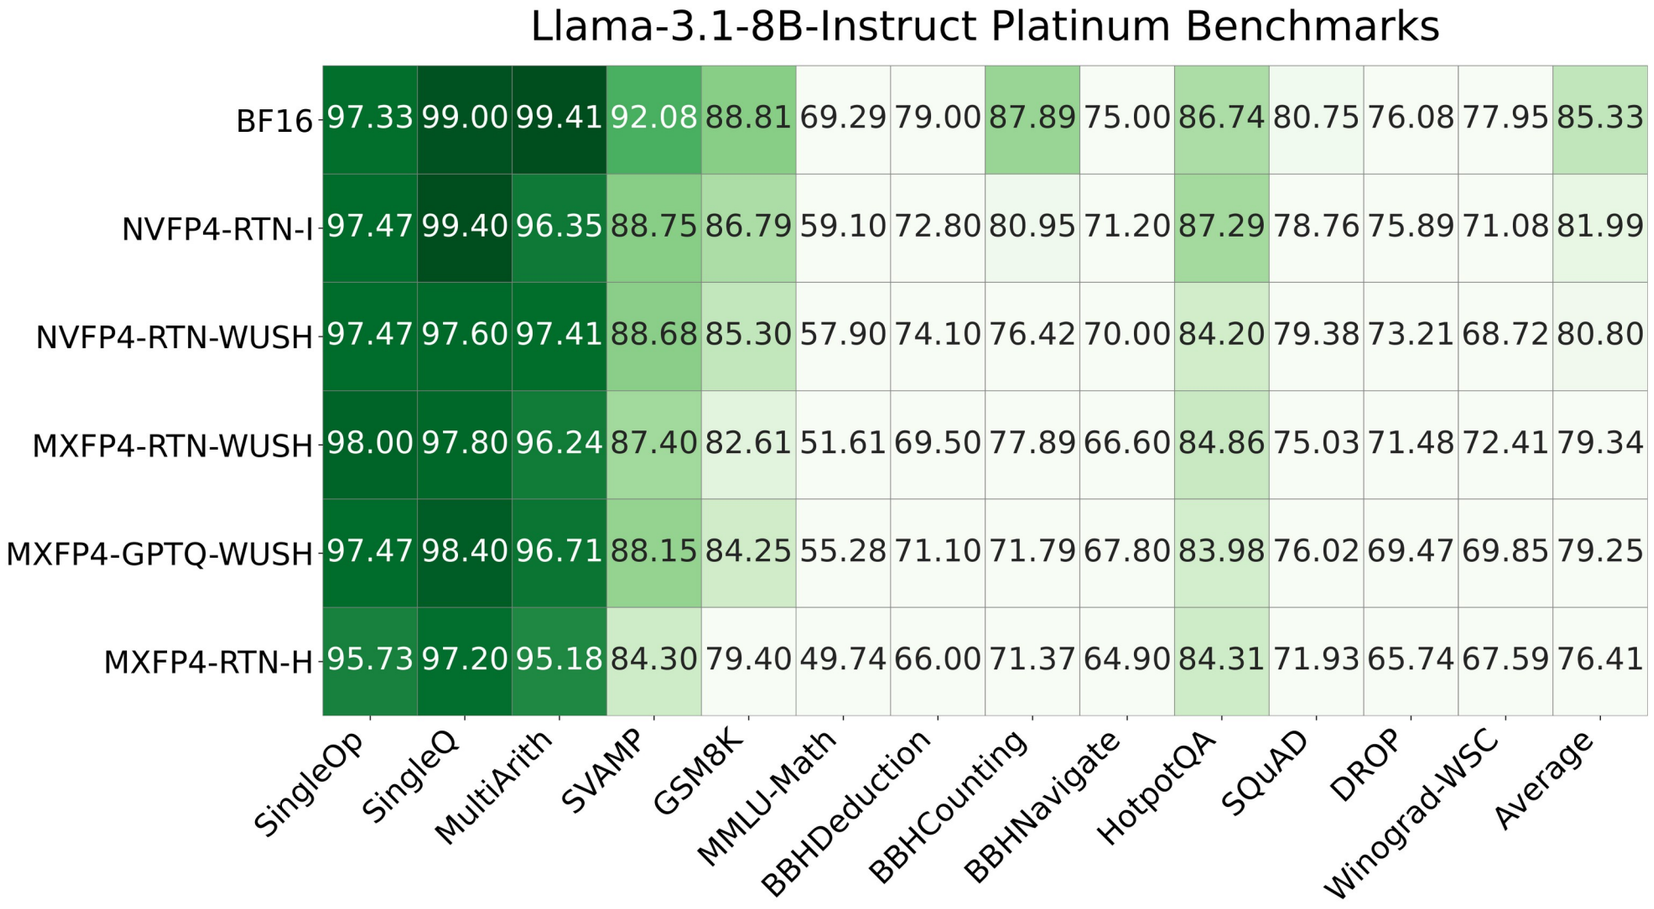
完整作者标题、 URL 、文件 SHA256 、许可和证据说明见 evidence.json 及逐页备注。

| ID | 工作 / 资料 | 论文编号 | 核验提交 |
|---|---|---|---|
| R08 | QUIK | 2310.09259 | 9558d71 |
| R09 | Atom | 2310.19102 | 7e3618b |
| R10 | MicroMix | 2508.02343 | c57370b |
| R11 | FP-Quant / MR-GPTQ | 2509.23202 | d2e3092 |
| R12 | WUSH | 2512.00956 | 0b69f66 |
| R13 | oneDNN datatype / MXFP8 tutorial | 主分支文档 | 4149450 |

图像仅复用明确 MIT / Apache 作者资产； MicroMix / Atom / SpinQuant 不复制插图。

# 附录： WUSH 作者原始任务明细表

Llama-3.1-8B-Instruct • 图 10 作者发布版本 • 原数据 / 标签未改动 • 可放大阅读




来源 R12 • Apache-2.0 • 完整许可在本页备注； PDF 包含许可附件。